

# Documento de Requisitos

## Prova Prática de Ciência de Dados e Big Data

### 1. Visão Geral do Trabalho

A entrega é dividida em **duas partes obrigatórias**:

- **Documentação no Confluence** (estrutura organizada em páginas, links e anexos quando necessário).
- **Código-fonte no Bitbucket ou GitHub** (repositório versionado, com branches organizadas e README).

O projeto consiste na construção de uma solução completa de Ciência de Dados/Big Data, envolvendo coleta, processamento, armazenamento e apresentação de insights. O trabalho deve ser realizado em **grupo de até 5 participantes**, porém a **avaliação é individual**, incluindo perguntas específicas feitas a cada integrante.

O objetivo é demonstrar domínio técnico, clareza conceitual e capacidade de estruturar um fluxo de dados robusto e bem documentado.

---

### 2. Entregáveis Obrigatórios

#### 2.1 Documentação Geral

A documentação deve incluir:

- **Descrição do problema** abordado pelo projeto.
  - **Objetivos do sistema** e justificativa técnica.
  - **Escopo da solução** (o que está incluído e o que não está).
  - **Arquitetura completa** do pipeline.
  - **Detalhes das ferramentas e tecnologias** utilizadas.
  - **Decisões técnicas** (trade-offs, alternativas consideradas e por quê).
  - **Guia de execução**: como rodar o projeto do zero.
  - **Guia de dependências** (versões de libs, serviços, containers e configurações).
  - **Descrição dos dados**: origem, formato, esquema, dicionário de dados.
  - **Pontos de falha e limitações**.
  - **Trabalho individual**: descrição breve das responsabilidades de cada integrante.
-

### 3. Arquitetura do Projeto

A arquitetura deve ser apresentada de forma clara, incluindo:

- **Diagrama de componentes** (pode ser UML, Data Flow Diagram, Mermaid, etc.).
  - **Fluxo do pipeline de dados** (ingestão → processamento → armazenamento → análise).
  - **Camadas da arquitetura** (Raw, Bronze, Silver, Gold, caso use Data Lake/Lakehouse).
  - **Descrição da infraestrutura**: containers, serviços externos, cluster ou nuvem.
  - **Explicação do formato dos dados** (Parquet, JSON, CSV, etc.).
  - **Estratégias de governança e qualidade de dados** (catalogação, validação, versionamento).
- 

### 4. Componentes Técnicos Esperados

#### 4.1 Ingestão de Dados

- Pode ser streaming (Kafka), batch (Airflow), ou ambos.
- Explicar como a coleta é agendada ou consumida.
- Incluir tratamentos básicos de pré-processamento.

#### 4.2 Processamento

- Pode usar Spark, Pandas, SQL, ou similar.
- Explicar transformações, agregações e cálculos.
- Detalhar lógica de negócio aplicada aos dados.

#### 4.3 Armazenamento

- Preferencialmente Data Lake (MinIO, S3, HDFS).
- Explicar camadas (Raw/Bronze, Silver, Gold).
- Justificar o formato usado.

#### 4.4 Análise e Visualização

- Pode usar Metabase, Grafana, Power BI, Superset ou dashboards customizados.
- Deve apresentar KPIs, métricas e visualizações com base nos dados tratados.

#### 4.5 API ou Interface (Opcional)

- Endpoint para servir dados processados.
- 

### 5. Critérios de Avaliação

A avaliação será focada de forma **individual**, considerando:

- Entendimento real da solução entregue.

- Capacidade de explicar componentes técnicos.
  - Clareza sobre seu papel no grupo.
  - Noções de arquitetura de dados.
  - Domínio das ferramentas utilizadas.
- 

## 6. Requisitos de Apresentação

A apresentação deve conter:

- Resumo do problema resolvido.
  - Demonstração do pipeline.
  - Explicação da arquitetura.
  - Melhorias que poderiam ser implementadas.
  - Perguntas individuais do avaliador.
- 

## 7. Organização do Repositório

O repositório deve conter:

- `/docs` — documentação completa.
  - `/src` — scripts e código-fonte.
  - `/infra` — Docker Compose, Terraform ou configs.
  - `/notebooks` — notebooks de análise exploratória.
  - `/datasets` — dados de teste.
  - `README.md` — guia de execução + visão geral.
- 

## 8. Considerações Finais

O trabalho deve refletir práticas reais de Engenharia e Ciência de Dados. Clareza, organização, justificativas técnicas e entendimento profundo do pipeline serão diferenciais marcantes na avaliação.

Este documento de requisitos serve como referência para garantir que o projeto final seja completo, bem estruturado e tecnicamente sólido. O próximo passo natural é transformar esses requisitos em tarefas distribuídas entre os membros do grupo.